TECHNISCHE UNIVERSITÄT
BERGAKADEMIE FREIBERG
Die Ressourcenuniversität. Seit 1765.

Advanced Programming SS 2020: LLVM

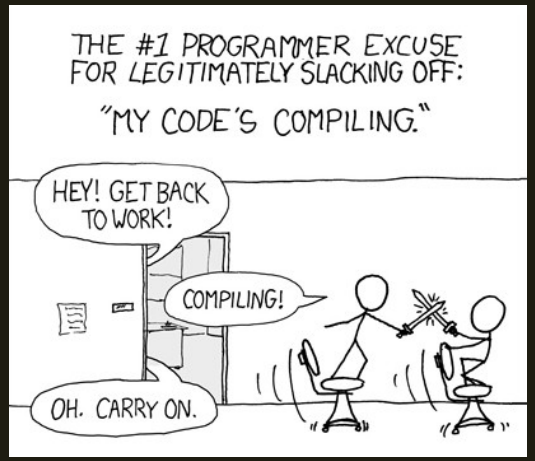

https://xkcd.com/303/

```
# Compute Ackermann's function
# for two parameters a and b.
def ack(a, b)
     if a == 0 then
          b + 1
     else if b == 0 then
          ack(a - 1, 1)
     else
          ack(a - 1, ack(a, b - 1))

def run(a, b)
     ack(a, b)
```

Ben Lorenz / Jonas Treumer

Compilerbau

- **Wie arbeitet ein Compiler?**

```c
#include <stdio.h>

int main(void)
{
    // My first C program!
    printf("Hello, world!\n");
    return 0;
}
```

Präprozessor

- Includes (Copy-Paste von Headern, rekursiv!)
- Kommentare entfernen
- Trigraphen ersetzen
- Makrosubstitution
- Bedingtes Übersetzen (`#ifdef` und Co.)

Compilerbau

- **Wie arbeitet ein Compiler?**

```
...

int main(void)
{
    printf("Hello, world!\n");
    return 0;
}
```

Präprozessor

- Includes (Copy-Paste von Headern, rekursiv!)
- Kommentare entfernen
- Trigraphen ersetzen
- Makrosubstitution
- Bedingtes Übersetzen (`#ifdef` und Co.)

Compilerbau

- **Wie arbeitet ein Compiler?**

```
...

int main(void)
{
    printf("Hello, world!\n");
    return 0;
}
```

Lexer

- Zerlegung des Codes in Tokens
- Entfernung von Whitespaces

Compilerbau

- **Wie arbeitet ein Compiler?**

```
...

keyword(`int`) ident(`main`) paren(`(`) keyword(`void`) paren(`)`)
paren(`{`)
ident(`printf`) paren(`(`) literal(`"Hello, world!\n"`) paren(`)`) semi(`;`)
keyword(`return`) literal(`0`) semi(`;`)
paren(`}`)
```

Lexer

- Zerlegung des Codes in Tokens
- Entfernung von Whitespaces

Compilerbau

- **Wie arbeitet ein Compiler?**

```
...

keyword(`int`) ident(`main`) paren(`(`) keyword(`void`) paren(`)`)
paren(`{`)
ident(`printf`) paren(`(`) literal(`"Hello, world!\n"`) paren(`)`) semi(`;`)
keyword(`return`) literal(`0`) semi(`;`)
paren(`}`)
```

Parser

- Gliedern der Tokens in höhersprachliche Konstrukte
- Hierarchische Anordnung → „Abstract Syntax Tree“ (AST)
- Verifikation: Nicht jedes Token ist überall erlaubt

Compilerbau

- **Wie arbeitet ein Compiler?**

```
func_def
(
   prototype: (name: main, ret: int, params: []),
   body:
   [
      call_stmt(func: printf, params: [str_literal(„Hello, world!\n“)]),
      ret_stmt(int_literal(0))
   ]
)
```

Parser

- Gliedern der Tokens in höhersprachliche Konstrukte
- Hierarchische Anordnung → „Abstract Syntax Tree“ (AST)
- Verifikation: Nicht jedes Token ist überall erlaubt

Compilerbau

- **Wie arbeitet ein Compiler?**

```
func_def
(
   prototype: (name: main, ret: int, params: []),
   body:
   [
      call_stmt(func: printf, params: [str_literal(„Hello, world!\n“)]),
      ret_stmt(int_literal(0))
   ]
)
```

Optimierer

- Extrem kompliziert!
- Evtl. Überführung in andere Zwischenrepräsentationen
- Teilweise plattformabhängig (z.B. durch Registeranzahl)

Compilerbau

- **Wie arbeitet ein Compiler?**

```
func_def
(
   prototype: (name: main, ret: int, params: []),
   body:
   [
      call_stmt(func: puts, params: [str_literal(„Hello, world!\n“)]),
      ret_stmt(int_literal(0))
   ]
)
```

Optimierer

- Extrem kompliziert!
- Evtl. Überführung in andere Zwischenrepräsentationen
- Teilweise plattformabhängig (z.B. durch Registeranzahl)

Compilerbau

- **Wie arbeitet ein Compiler?**

```
func_def
(
   prototype: (name: main, ret: int, params: []),
   body:
   [
      call_stmt(func: puts, params: [str_literal(„Hello, world!\n“)]),
      ret_stmt(int_literal(0))
   ]
)
```

Codegenerator

- Überführung in Assembler für die Zielplattform

Compilerbau

- **Wie arbeitet ein Compiler?**

```
sub     rsp,0x8
lea     rdi,[rip+0xfb9]
call    0x1030 <puts@plt>
xor     eax,eax
add     rsp,0x8
ret
```

Codegenerator

- Überführung in Assembler für die Zielplattform

Compilerbau

- **Wie arbeitet ein Compiler?**

```
sub     rsp,0x8
lea     rdi,[rip+0xfb9]
call    0x1030 <puts@plt>
xor     eax,eax
add     rsp,0x8
ret
```

Assembler

- Generierung von Maschinencode
- Überführung in Objektdatei (z.B. ELF)

Compilerbau

- **Wie arbeitet ein Compiler?**

```
48 83 ec 08
48 8d 3d b9 0f 00 00
e8 e0 ff ff ff
31 c0
48 83 c4 08
c3
```

Assembler

- Generierung von Maschinencode
- Überführung in Objektdatei (z.B. ELF)

Compilerbau

- **Wie arbeitet ein Compiler?**

```
48 83 ec 08
48 8d 3d b9 0f 00 00
e8 e0 ff ff ff
31 c0
48 83 c4 08
c3
```

Linker

- Verknüpfung mit weiteren Objektdateien
- Auflösung von Funktionsverweisen

Compilerbau

- **Monolithisches Modell**

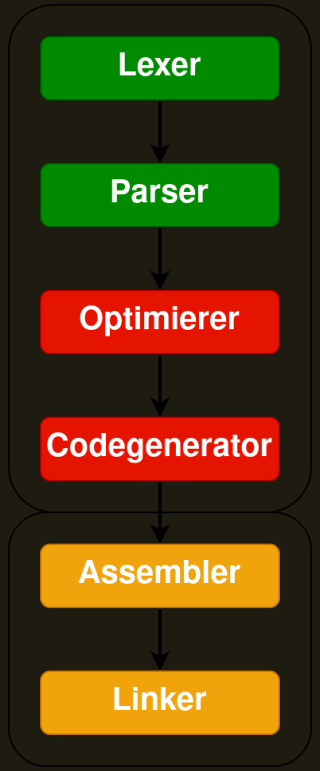

Compiler

Platform Toolchain

Compilerbau

- **Monolithisches Modell**

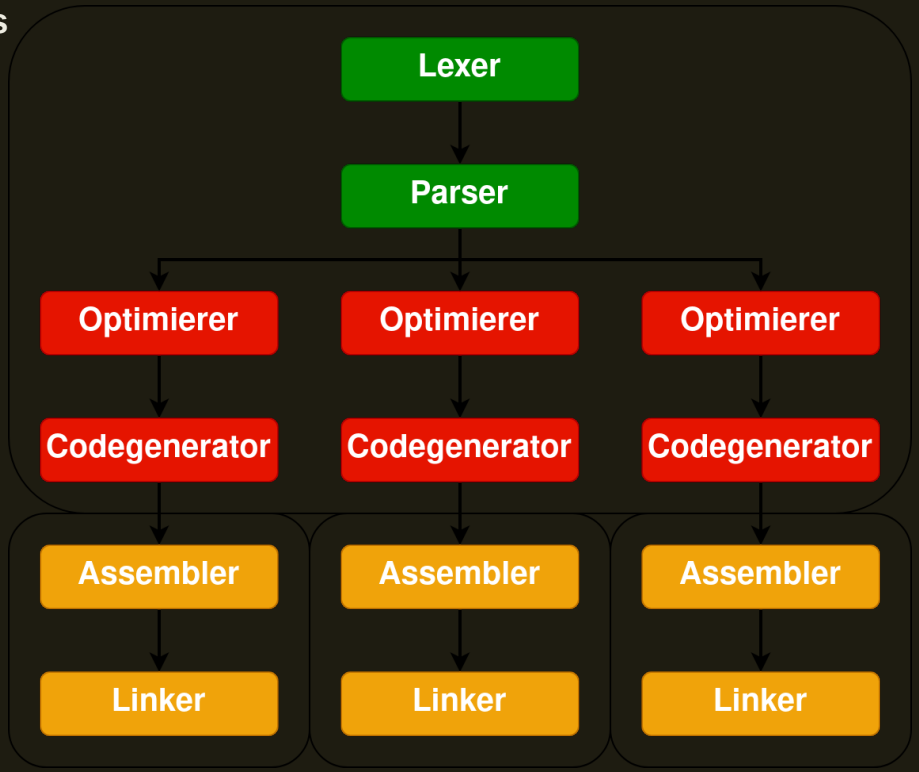

Compilerbau

- **Geteiltes Modell**

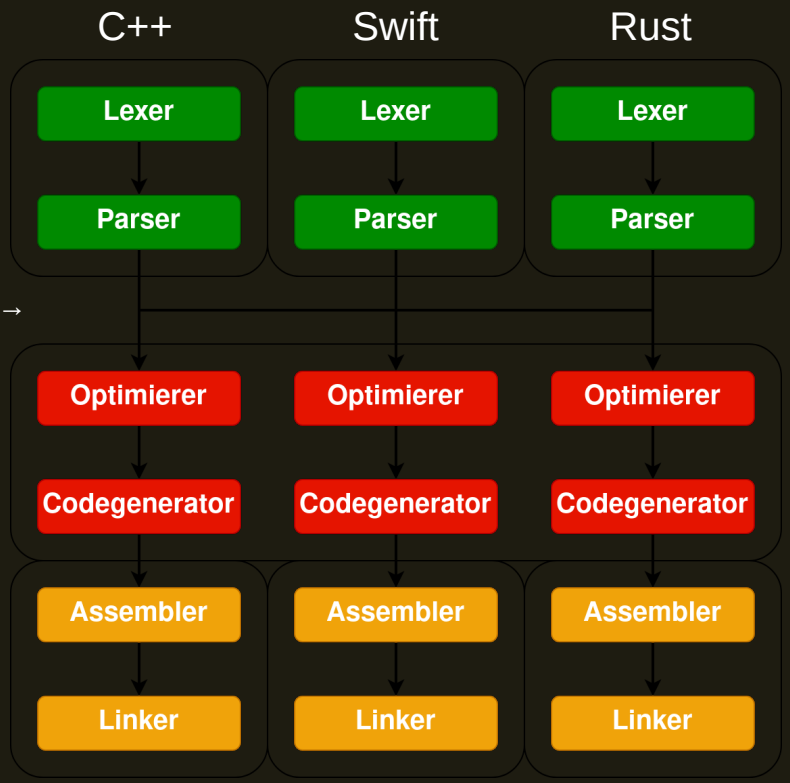

Compiler Frontends

Compiler Backend

Platform Toolchains

Compilerbau

- **LLVM**

Compilerbau

- **LLVM**
  - Open-Source-Projekt an der Universität von Illinois (2000, Chris Lattner / Vikram Adve)
  - Ursprünglich: „*Low Level Virtual Machine*“
  - LLVM-IR: Zwischensprache, ähnlich einem High-Level-Assembler
  - Schnittstellen zur Generierung von LLVM-IR aus ASTs
  - Komplexe, ausgereifte Optimierung von LLVM-IR („Passes“)
  - Übersetzung in plattformspezifischen Assembler
  - JIT-Compiler-Unterstützung

Compilerbau

- **Wer nutzt LLVM?**
  - **clang**: Compiler für C / C++, Drop-In-Replacement für gcc
  - **GHC**: Glasgow Haskell Compiler
  - **Julia**: Programmiersprache mit Fokus auf numerische / wissenschaftliche Berechnungen und hohe Performanz
  - **Swift**: Objektorientierte Programmiersprache für Apple-Ökosystem (inzwischen auch Linux), App-Programmierung (siehe z.B. „Swift-UI“), funktionale Aspekte, ARC, hohe Performanz
  - **Rust**: Systemnahe Programmiersprache, Performanz im Bereich von C / C++, Speichersicherheit durch Ownership / Borrowchecker, objektorientierte Anleihen (aber keine Vererbung), funktionale Aspekte
  - **Kotlin Native**: Kotlin außerhalb der JVM

Compilerbau

- **LLVM-Tutorial**
  - Bester Einstieg: Entwurf einer Spielzeug-Programmiersprache
  - Implementierung von Lexer / Parser, Generierung von LLVM-IR
  - Tutorial: Ocaml (https://llvm.org/docs/tutorial/)
  - C++ (https://llvm.org/docs/tutorial/MyFirstLanguageFrontend/index.html)
  - Third-Party-Ports für andere Sprachen
  - Heute und in den nächsten drei Veranstaltungen: **LLVM-Tutorial in C#**
    - Lexer
    - Parser
    - IR-Generierung
    - Optimierung, Feinschliff

Compilerbau

- **Kaleidoscope:** Spielzeug-Programmiersprache
  - Nur ein Datentyp: Double-Precision Floating Point (IEEE 754) → keine Annotationen
  - Funktionen: ein Rückgabewert, beliebig viele Parameter
  - „Expression-based“: wie Kotlin (bzw. noch näher an Rust), aber gänzlich ohne Statements und Variablen

```
def sqr(x)
    x * x
```

  - Operatoren: `+`, `-`, `*`, `/` mit üblicher Rangfolge, außerdem: Klammern

```
def avg(a, b)
    0.5 * (a + b)
```

Compilerbau

- **Kaleidoscope:** Spielzeug-Programmiersprache
  - Boolesche Operatoren: `==`, `<`, `>`, `<=`, `>=` liefern Double zurück (1.0 für `true`, 0.0 für `false`)
  - Bedingte Anweisungen: `if-then-else` (alles erforderlich)

```
def abs(x)
    if x < 0 then
        -1 * x
    else
        x
```

  - Kommentare mit #, Funktionsaufrufe wie in C:

```
# Calculates the absolute average
def abs_avg(a, b)
    abs(avg(a, b))
```

Compilerbau

- **Kaleidoscope:** Spielzeug-Programmiersprache
  - Rekursion:

```
# Computes the n'th Fibonacci number
def fib(n)
    if n < 2 then
        n
    else
        fib(n - 2) + fib(n - 1)
```

  - Generell gilt: Funktionen müssen vor ihrem Aufruf deklariert sein.
  - Statt Definition: Forwärtsdeklaration

```
# Computes the n'th Fibonacci number
dec fib(n)
```

Compilerbau

- **Kaleidoscope:** Spielzeug-Programmiersprache
  - Gegen `libm` linken → Funktionen aus der Mathebibliothek nutzen

```
dec sin(x)
dec cos(x)
dec pow(base, epx)

def trig(x)
    pow(sin(x), 2) + pow(cos(x), 2)
```

Compilerbau

- **Kaleidoscope:** Spielzeug-Programmiersprache

The command line arguments are listed and explained below.

- `-h` / `--help` : Print a short manual.
- `-o` / `--output-path` : Define the directory where output files shall be written to. By default, they land in the same directory as the source file.
- `-s` / `--stage` : Define up to which stage the compiler shall proceed and which kind of output shall be generated. The six stages are:
  - `lex` : Run the lexer on the source file and dump the resulting token stream into a `.lex` file.
  - `ast` : Run the parser on the output of the lexer and dump the resulting abstract syntax tree (AST) into a `.ast` file.
  - `ir` : Transform the AST to LLVM's object model, generate IR code from it and dump it into a `.ll` file.
  - `asm` : Translate the IR into the platform's native assembly syntax and dump it into a `.s` file.
  - `obj` : Assemble to native machine code and dump it into a `.o` file.
  - `exe` : Create a Makefile project including the object code file and a light C shim to provide an entry point for the operating system.
- `-O` / `--optimize` : Run a bunch of LLVM's optimizer passes on the resulting IR to generate more efficient code.
- `-t` / `--target` : By passing a target triple with this option, `kalc` supports a basic cross-compilation mode. Use with care, this does not work well with the `exe` stage.

In addition to the described arguments, a non-optional input file path has to be specified. Its file name determines the name of the output (and is assigned to the generated module).

Compilerbau

- **Lexer**
  - Gegeben: `Token`-Klasse
  - Algebraischer Datentyp: Enum mit Payloads, die von der Variante abhängen (Swift, Rust) → Emulation in C#

```
public enum TokenType
{
    EndOfFile,
    Keyword,
    Bracket,
    Identifier,
    Number,
    Operator,
    ParameterSeparator,
    Comment,
}
```

Compilerbau

- **Lexer**
  - Gegeben: `Token`-Klasse
  - Algebraischer Datentyp: Enum mit Payloads, die von der Variante abhängen (Swift, Rust) → Emulation in C#

```
public enum TokenType
{
    EndOfFile,
    Keyword,
    Bracket,
    Identifier,
    Number,
    Operator,
    ParameterSeparator,
    Comment,
}
```

```
public enum Keyword
{
    Dec,
    Def,
    If,
    Then,
    Else,
}
```

Compilerbau

- **Lexer**
  - Gegeben: `Token`-Klasse
  - Algebraischer Datentyp: Enum mit Payloads, die von der Variante abhängen (Swift, Rust) → Emulation in C#

```
public enum TokenType
{
    EndOfFile,
    Keyword,
    Bracket,
    Identifier,
    Number,
    Operator,
    ParameterSeparator,
    Comment,
}
```

```
public enum Bracket
{
    RoundStart,
    RoundEnd,
}
```

Compilerbau

- **Lexer**
  - Gegeben: `Token`-Klasse
  - Algebraischer Datentyp: Enum mit Payloads, die von der Variante abhängen (Swift, Rust) → Emulation in C#

```
public enum TokenType
{
    EndOfFile,
    Keyword,
    Bracket,
    Identifier,
    Number,
    Operator,
    ParameterSeparator,
    Comment,
}
```

```
public enum Operator
{
    Add,
    Subtract,
    Multiply,
    Divide,
    Equal,
    LowerThan,
    LowerThanEqual,
    GreaterThan,
    GreaterThanEqual,
}
```

Compilerbau

- **Lexer**
  - Gegeben: `Token`-Klasse
  - Algebraischer Datentyp: Enum mit Payloads, die von der Variante abhängen (Swift, Rust) → Emulation in C#
  - `Type`-Property zum Abfragen
  - Spezifische Properties, die im Getter den Typ validieren: `Keyword`, `Bracket`, `Identifier` etc.
  - Privater Konstruktor, stattdessen statische Methoden mit Payload-Parametern: `NewKeyword(Keyword keyword)`, `NewBracket(Bracket bracket)`, `NewIdentifier(string identifier)` etc.
  - `ToString()`-Methode für „Pretty Printing“

Compilerbau

- **Lexer**
  - Gegeben: `Lexer`-Klasse
  - `Character`-Struct: ebenfalls algebraisch (`char` oder `EndOfFile`)
  - Privates `Character`-Feld, wird über die private `EatChar()`-Methode konsumiert
  - Konstruktor kapselt einen `TextReader`
  - **(Haus-)Aufgaben für heute:**
    - In den Quellcode einarbeiten (auch `Compiler.cs` mal anschauen!)
    - Die Lexer-Klasse vervollständigen
    - Mit den gegebenen Beispieldateien (`samples` bzw. `samples/lex`) testen